

# AMIRec: Adaptive Multi-Interest Recommendation

디이전트

김서정 (2023149032)

민세희 (2022149010)

이재영 (2021122063)

정지윤 (2022148072)

## Introduction

사용자의 관심사는 단일하지 않으며, 시간의 흐름에 따라 지속적으로 변화하는 다중 관심사(Multi-Interest) 구조를 가진다. 그러나 기존 추천 시스템의 대부분은 사용자의 관심사를 단일 벡터로 표현하거나, 고정된 개수( $K$ )의 관심사를 가정하는 방식으로 설계되어 있어 이러한 동적인 관심사 변화를 충분히 반영하지 못한다는 한계가 있다. 특히 사용자의 행동 패턴이 특정 시점을 기준으로 급격히 변화하거나, 기존에 없던 새로운 관심사가 등장하는 경우(Long-tail Interest), 고정  $K$  기반 모델은 이를 효과적으로 포착하기 어렵다.

따라서 본 연구에서는 사용자 행동 시퀀스를 기반으로, 시간에 따라 변화하는 다중 관심사를 동적으로 모델링하여 이를 해결하고자 한다.

## Background and Related Work

### Fixed-K-Multi-Interest Representation

Single vector representation의 한계를 극복하기 위해 사용자를 여러 개의 관심사 벡터로 표현하는 multi-interest 모델이 제안되었다. 대표적인 연구인 MIND (Multi-Interest Network with Dynamic Routing)<sup>[1]</sup>에서는 사용자의 행동 시퀀스로부터 여러 개의 관심사 벡터를 추출한다. 사용자 행동을 여러 개의 관심사 그룹으로 분리하고 사용자 representation을  $u = \{u_1, \dots, u_k\}$  로 구성하여, 특정 관심사를 반영하고 아이템과의 유사도를 기반으로 관심사별로 다른 추천을 수행할 수 있다. 하지만 관심사 개수  $K$ 를 사전에 고정한다는 한계를 가진다. 실제로는 사용자마다 필요한 관심사 개수가 다르기 때문에 고정된  $K$ 를 사용하면 불필요하게 관심사를 분할하거나 여러가지 관심사가 합쳐지는 문제가 발생한다. 또한 사용자의 관심사는 시간에 따라 개수가 변화할 수도 있는데  $K$ 를 고정시켜놓으면 이러한 변화를 반영하기 어렵다.

## Temporary Dynamics 미반영

“Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks”<sup>[2]</sup>에서는 사용자와 아이템의 시간에 따른 변화하는 **embedding trajectory**를 학습한다. JODIE 모델은 사용자와 아이템을 각각 시간에 따라 변하는 함수로 표현하며, 각 **interaction**이 발생할 때마다 **embedding**을 업데이트하고, 그 변화가 연속적인 **trajectory**를 이룬다고 본다. 이를 위해 두 개의 **RNN**을 사용하여 사용자와 아이템 **embedding**을 상호 의존적으로 업데이트한다. 단순히 현재 상태만이 아니라 미래 시점의 **embedding**을 예측하여 미래 **interaction**을 직접 예측한다. 그러나 여전히 특정 시점의 사용자의 상태가 하나의 벡터로 표현되어 여러 관심사가 동시에 존재하는 구조는 반영되지 않는다. 그리고 이 모델은 “관심사의 분리”가 아니라 “상태의 연속적 변화”에 초점을 맞추고 있기 때문에 사용자의 복수 관심사 구조를 명시적으로 모델링하지 않는다. 또한, **multi-interest representation**이나 **adaptive K** 구조와는 결합되어 있지 않다.

## Proposed Research

본 연구에서는 시간에 따라 변화하는 사용자의 관심사 개수와 벡터를 데이터 밀도에 기반하여 생성하는 ‘적응형 다중 관심사 추천 시스템(Adaptive Multi-Interest Recommendation)’을 제안한다.

기존에 존재하는 문제점들을 해결하기 위해 다음과 같은 4단계 파이프라인을 구성한다.

### 1. 사용자 상태 임베딩

사용자의 과거 선호 영화 시퀀스  $S_u = \{i_1, i_2, \dots, i_N\}$ 를 입력받아 시퀀스 내 아이템 간의 문맥적인 관계가 반영된 고차원 표현 벡터로 변환한다. 이때 시점별 사용자 상태는 다음으로 정의된다.

$$h_t = f(i_1, \dots, i_t)$$

출력된 벡터는  $h_t \in R^d$  (e.g.,  $d=128$ ) 형태를 가진다. Transformer 기반의 SASRec<sup>[3]</sup>을 기본 아키텍처로 채택하였으나, 모델의 일반화 성능과 구조를 검증하기 위해 시퀀스를 반영하지 않는 경량 모델 또한 적용하여 비교 분석한다.

### 2. Manifold 차원 축소

임베딩된 고차원 공간에서는 유클리디안 거리 기반의 군집화가 정상적으로 작동하지 않는 한계가 존재한다. 이를 해결하고자 UMAP<sup>[4]</sup> 알고리즘을 도입하여, 시퀀스 데이터의 고차원 특징을 저차원 공간으로 압축한다.

$$h_t \in R^{128} \rightarrow z_t \in R^3$$

### 3. 밀도 기반 Adaptive Clustering

압축된 차원 공간  $R^3$ 에서 HDBSCAN<sup>[6]</sup> 알고리즘을 적용하여 데이터의 밀도를 분석한다.  $K$ 값을 사전 지정하는 기존 방식 대신, 밀도가 높은 영역을 유효한 관심사 클러스터  $C_k$ 로 묶고 밀도가 낮은 점들은 노이즈로 필터링함으로써 유효 관심사의 개수  $K$ 를 동적으로 도출한다.

### 4. 관심사 벡터 계산 및 스코어링

노이즈를 제외한 라벨별 원본 고차원 임베딩( $h_t$ )의 평균을 계산하여  $k$ 개의 관심사 중심점 벡터  $u_k$ 를 도출한다.

$$u_k = \frac{1}{|C_k|} \sum_{t \in C_k} h_t$$

이후 도출된  $K$ 개의 관심사 벡터  $u_k$ 와 타겟 아이템 벡터  $v_i$ 간의 내적을 통해 유사도 점수  $s_k(i) = u_k^T v_i$ 를 계산하고, 최종 추천 점수를 산출한다.

## Experiment

### 데이터셋

본 연구에서는 두 종류의 데이터를 활용한다. 행동 데이터로는 MovieLens 32M 데이터셋을 사용하며, 약 200,000명의 사용자가 87,000여 편의 영화에 부여한 3,200만 건의 평점 데이터로 구성되어 있다. 각 평점에 timestamp가 포함되어 있어 시퀀스 구성이 가능하다. Semantic 데이터로는 MovieLens Tag Genome Dataset과 IMDb 영화 설명 데이터를 활용하며, 아이템 임베딩 보강과 HDBSCAN 클러스터링 결과의 의미적 타당성 사후 검증에 사용한다.

### 데이터 전처리

사용자마다 평점 부여 패턴이 상이하므로 절대적 기준 대신 사용자별 z-score 표준화를 적용하여,  $z > 0$ 인 항목을 긍정 상호작용으로 정의한다. 필터링된 아이템은 timestamp 순으로 정렬하여 시퀀스를 구성하며, 상호작용 수가 일정 건수 미만인 cold-start 사용자는 제외한다. 시퀀스 길이는 최근  $N$ 개로 truncate하되, 여러  $N$  값으로 실험하여 길이가 성능에 미치는 영향을 분석한다. 학습/검증/테스트 분할은 시간 기준 글로벌 split을 채택하여, 미래 데이터의 학습 유입을 방지하고 실제 서비스 시나리오를 반영한다.

## 비교 모델

단일 관심사 모델로는 SASRec과 GRU4Rec<sup>[6]</sup>을, 다중 관심사 모델로는 MIND, ComiRec<sup>[7]</sup>을 선정한다. SASRec은 제안 방법과 동일한 인코더를 사용하되 관심사 분리를 수행하지 않는 상한선 역할이며, MIND와 ComiRec 계열은 모두 관심사 개수  $K$ 를 사전 고정한다는 점에서 제안 방법의 적응형  $K$  도출과 직접 비교된다.

## 평가 지표

정확도 지표로 Recall@K, NDCG@K, Hit Rate@K를 사용하며, 다중 관심사 모델에서는 타겟 아이템과 가장 높은 유사도를 보이는 관심사 벡터 기준으로 측정한다. 다양성 측면에서는 Coverage, 사용자별 클러스터 수 분포, 그리고 Tag Genome 기반의 클러스터 의미 정합성 정성 평가를 추가로 리포트한다.

## Research Schedule

| week                           | 01 (3/3) | 02 (3/10) | 03 (3/17) | 04 (3/24) | 05 (3/31) | 06 (4/7) | 07 (4/14) | 08 (4/21) | 09 (4/28) | 10 (5/5) | 11 (5/12) | 12 (5/19) | 13 (5/26) | 14 (6/2) | 15 (6/9) |
|--------------------------------|----------|-----------|-----------|-----------|-----------|----------|-----------|-----------|-----------|----------|-----------|-----------|-----------|----------|----------|
| 연구주제 선정                        |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 연구제안서 작성/제출                    |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 참고논문 탐구                        |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 데이터 전처리 /<br>파이프라인 구축          |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| SASRec 인코더 구현                  |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 중간보고서/발표자료 제작                  |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 중간발표                           |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| UMAP + HDBSCAN<br>파이프라인 구현     |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 베이스라인 모델 구현<br>(MIND, ComiRec) |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| Ablation / 비교 실험<br>및 결과 도출    |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 최종보고서/발표자료 제작                  |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 최종발표                           |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 전시회                            |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |
| 최종보고서 제출                       |          |           |           |           |           |          |           |           |           |          |           |           |           |          |          |

## Team member

- 김서정 (팀장): 스코어링 및 최종 추천 결과 산출
- 민세희: 임베딩 모델 설계 및 구현

- 이재영 : 데이터셋 정제 및 데이터 파이프라인 구축
- 정지윤 : 클러스터링 기반 모델링 설계 및 구현
  
- 이동하 : 담당 교수
- 김성환 : 담당 대학원생
- 박진성 : 산학 멘토

## References

### [1] MIND

Li, C., Liu, Z., Wu, M., Xu, Y., Zhao, H., Huang, P., Kang, G., Chen, Q., Li, W., & Lee, D. L. (2019).

Multi-Interest Network with Dynamic Routing for Recommendation at Tmall.

In Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19), 2615–2623.

### [2] JODIE

Kumar, S., Zhang, X., & Leskovec, J. (2019).

Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks.

In Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '19), 1269–128.

### [3] SASRec

Kang, W. C., & McAuley, J. (2018).

Self-Attentive Sequential Recommendation.

In Proceedings of the 2018 IEEE International Conference on Data Mining (ICDM), 197–206.

### [4] UMAP

McInnes, L., Healy, J., Saul, N., & Großberger, L. (2018).

UMAP: Uniform manifold approximation and projection.

*Journal of Open Source Software*, 3(29), 861.

### [5] HDBSCAN

Campello, R. J., Moulavi, D., & Sander, J. (2013).

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining: 17th Pacific-Asia Conference, PAKDD 2013, Gold Coast, Australia, April 14-17, 2013, Proceedings, Part II 17* (pp. 160-172). Springer Berlin Heidelberg.

### [6] GRU4rec

Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016).

Session-based Recommendations with Recurrent Neural Networks.  
In Proceedings of the International Conference on Learning Representations (ICLR 2016).

[7] ComiRec

Cen, Y., Lin, J., Zhang, J., Zhou, K., Yang, H., & Zhao, W. X. (2020).

Controllable Multi-Interest Framework for Recommendation.

In Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '20).