

AMIRec: Adaptive Multi-Interest Recommendation

다이전트

김서정 (2023149032)

민세희 (2022149010)

이재영 (2021122063)

정지윤 (2022148072)

Introduction

사용자의 관심사는 단일하지 않으며, 시간의 흐름에 따라 지속적으로 변화하는 다중 관심사(Multi-Interest) 구조를 가진다. 그러나 기존 추천 시스템의 대부분은 사용자의 관심사를 단일 벡터로 표현하거나, 고정된 개수(K)의 관심사를 가정하는 방식으로 설계되어 있어 이러한 동적인 관심사 변화를 충분히 반영하지 못한다는 한계가 있다. 특히 사용자의 행동 패턴이 특정 시점을 기준으로 급격히 변화하거나, 기존에 없던 새로운 관심사가 등장하는 경우(Long-tail Interest), 고정 K 기반 모델은 이를 효과적으로 포착하기 어렵다.

따라서 본 연구에서는 사용자 행동 시퀀스를 기반으로, 시간에 따라 변화하는 다중 관심사를 동적으로 모델링하여 이를 해결하고자 한다.

Background and Related Work

Fixed-K-Multi-Interest Representation

Single vector representation의 한계를 극복하기 위해 사용자를 여러 개의 관심사 벡터로 표현하는 multi-interest 모델이 제안되었다. 대표적인 연구인 MIND (Multi-Interest Network with Dynamic Routing)^[1]에서는 사용자의 행동 시퀀스로부터 여러 개의 관심사 벡터를 추출한다. 사용자 행동을 여러 개의 관심사 그룹으로 분리하고 사용자 representation을 $u = \{u_1, \dots, u_k\}$ 로 구성하여, 특정 관심사를 반영하고 아이템과의 유사도를 기반으로 관심사별로 다른 추천을 수행할 수 있다. 하지만 관심사 개수 K 를 사전에 고정한다는 한계를 가진다. 실제로는 사용자마다 필요한 관심사 개수가 다르기 때문에 고정된 K 를 사용하면 불필요하게 관심사를 분할하거나 여러가지 관심사가 합쳐지는 문제가 발생한다. 또한 사용자의 관심사는 시간에 따라 개수가 변화할 수도 있는데 K 를 고정시켜놓으면 이러한 변화를 반영하기 어렵다.

Single-state Temporal Dynamics

“Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks”^[2]에서는 사용자와 아이템의 시간에 따른 변화하는 **embedding trajectory**를 학습한다. JODIE 모델은 사용자와 아이템을 각각 시간에 따라 변하는 함수로 표현하며, 각 **interaction**이 발생할 때마다 **embedding**을 업데이트하고, 그 변화가 연속적인 **trajectory**를 이룬다고 본다. 이를 위해 두 개의 **RNN**을 사용하여 사용자와 아이템 **embedding**을 상호 의존적으로 업데이트한다. 단순히 현재 상태만이 아니라 미래 시점의 **embedding**을 예측하여 미래 **interaction**을 직접 예측한다. 그러나 여전히 특정 시점의 사용자의 상태가 하나의 벡터로 표현되어 여러 관심사가 동시에 존재하는 구조는 반영되지 않는다. 그리고 이 모델은 “관심사의 분리”가 아니라 “상태의 연속적 변화”에 초점을 맞추고 있기 때문에 사용자의 복수 관심사 구조를 명시적으로 모델링하지 않는다. 또한, **multi-interest representation**이나 **adaptive K** 구조와는 결합되어 있지 않다.

Novelty and Contributions

기존 **multi-interest** 연구들은 대부분 사용자 **representation**을 정적인 벡터 집합으로 정의하거나, 단순한 행동 집합을 기반으로 관심사를 분리하는 방식에 머물러 있었다. 그러나 이러한 접근은 사용자 행동의 순서 정보(**sequence dynamics**)를 충분히 반영하지 못한다는 한계를 가진다.

MIND와 같은 **fixed-K** 기반 **multi-interest** 모델은 관심사의 복수성은 파악할 수 있으나 관심사 개수의 가변성이나 시간적 변화는 담지 못한다. JODIE와 같은 **temporal dynamics** 모델은 시간에 따른 상태 변화는 추적하지만 다중 관심사를 명시적으로 표현하지 못한다. 즉, **multi-interest** 구조와 **temporal dynamics**는 독립적으로 연구되어 왔으며, 두 양상을 통합적으로 모델링하는 연구는 충분히 이루어지지 않았다.

본 연구에서는 **sequence-aware representation** 위에서 **density-based clustering**을 적용하여 관심사 개수 **K**개를 데이터로부터 적응적으로 결정하고, 시간 축을 따라 관심사의 생성·소멸·변화를 추적할 수 있는 구조를 제안한다. 이는 사용자마다 서로 다른 여러 관심사를 가지는 특성과, 단일 사용자의 관심도도 시간에 따라 생성 및 소멸되는 특성을 동시에 모델링한다는 점에서 의의가 있다. 또한 **long-tail interest**나 **interest shift**를 명시적으로 표현함으로써 추천 결과의 다양성과 최신성을 함께 개선할 수 있을 것으로 기대된다.

더 나아가 본 연구는 제안한 **adaptive multi-interest** 구조를 실제 산업 환경에서 활용 가능한 추천 시스템 파이프라인 형태로 구현하고 검증하고자 한다. 현실의 추천 시스템에서는 사용자의 클릭, 시청, 검색, 구매와 같은 **interaction**이 시간 순서에 따라 지속적으로 발생하며, 추천 모델은 이러한 행동 변화를 빠르게 반영할 수 있어야 한다. 따라서 본 연구는 정적인 데이터셋 위에서 관심사 클러스터를 분석하는 데 그치지 않고, **streaming** 방식의 데이터 처리 구조를 도입하여 새롭게 유입되는 사용자 행동을 **representation update**, **interest clustering**, **recommendation scoring** 과정에 반영할 수 있는 구조로 확장하고자 한다.

이를 통해 본 연구는 **adaptive multi-interest modeling**의 학술적 가능성을 제시하는 동시에, 해당 아이디어가 실제 서비스형 추천 시스템에서도 적용 가능한지를 검증하는 엔지니어링적 솔루션을 함께 제공하고자 한다.

Proposed Research

End-to-End 데이터 파이프라인 구축 및 시퀀스 데이터 정제

기존 추천 시스템 연구에서는 데이터 전처리 과정이 명확히 정의되지 않거나, 실험 환경에 따라 재현성이 떨어지는 문제가 존재한다.

본 연구에서는 **MovieLens 32M** 데이터셋을 기반으로, **ratings, movies, tags, links** 데이터를 통합하여 일관된 **schema**를 구성하고, 사용자별 시간 순서 시퀀스를 생성하였다.

특히 다음과 같은 특징을 갖는 전처리 파이프라인을 구축하였다:

- 영화 메타데이터 통합 (장르 + 태그 정보 포함)
- 사용자별 **timestamp** 기반 시퀀스 생성
- 추천/학습용 데이터 분리 (**time-based split**)
- **schema** 기반 **validation**을 통한 데이터 정합성 확보

이를 통해 이후 모델링 및 클러스터링 단계에서 활용 가능한 고품질 **sequential dataset**을 구축하였다.

Sequence-aware Representation Learning 기반 사용자 상태 모델링

본 연구에서는 **Transformer** 기반의 **SASRec^[3]** 모델을 활용하여, 사용자 행동 시퀀스를 반영한 시점별 사용자 상태 표현(**hidden state**)을 학습하였다. 구체적으로, 각 시점 t 에서의 사용자 상태는 다음과 같이 정의된다:

$$h_t = f(i_1, i_2, \dots, i_t)$$

여기서 $h_t \in R^{128}$ 는 해당 시점까지의 모든 행동을 반영한 **contextual embedding**이다.

또한 단순한 **next-item prediction loss**뿐만 아니라 **contrastive loss**를 함께 적용하여,

- 유사한 행동 패턴을 가진 시점 간 **representation**은 가깝게
- 서로 다른 관심사를 반영하는 시점은 멀어지도록 표현 공간을 구조화하였다.

이를 통해 기존 연구 대비 **sequence-aware + semantic-aware representation**을 확보하였다.

Manifold 기반 차원 축소를 통한 Representation Geometry 개선

고차원 임베딩 공간에서는 거리 기반 군집화가 제대로 동작하지 않는 문제가 존재한다. 특히 **cosine similarity** 또는 **Euclidean distance**가 실제 **semantic structure**를 반영하지 못하는 경우가 많다.

이를 해결하기 위해 본 연구에서는 **UMAP**^[4]을 활용하여

$$h_t \in R^{128} \rightarrow z_t \in R^{10}$$

으로 차원을 축소하였다.

이 과정에서 **global UMAP**을 전체 시점에 대해 한 번 수행하여, 전체 **embedding space**의 **manifold structure**를 보존하면서 이후 **clustering**에 적합한 저차원 표현을 생성하였다. 이는 단순 **PCA** 기반 축소와 달리, **local density**와 **topology**를 유지한다는 점에서 **clustering** 성능 향상에 기여한다.

Density-based Adaptive Clustering의 실험적 구현

기존 **multi-interest** 모델의 핵심 한계는 관심사 개수 **K**를 사전에 고정한다는 점이다.

이를 해결하기 위한 방향으로, 본 연구에서는 **HDBSCAN**^[6]을 활용한 **density-based clustering** 구조를 실제로 구현 및 실험 단계까지 진행하였다.

현재까지는 다음과 같은 두 가지 방식의 클러스터링을 수행하였다:

1. Global HDBSCAN

- 전체 시점 **T**에 대해 한 번에 **clustering** 수행
- 전체 사용자 상태 공간에서의 전역적 관심사 구조 파악
- 이후 관심사 벡터 계산 및 스코어링에 활용 예정

2. Sliding Window HDBSCAN

- 시간 축을 따라 **window**를 이동시키며 독립적으로 **clustering** 수행
- 각 구간에서의 관심사 변화를 반영
- **temporal dynamics + adaptive K**를 동시에 반영하려는 시도

이 과정에서 **HDBSCAN**은 클러스터 개수를 자동으로 결정하고, 밀도가 낮은 영역을 **noise**로 처리함으로써, 기존 **fixed-K** 방식 대비 유연한 관심사 분리 구조를 제공한다.

Progress and Future Work

현재까지는 사용자 행동 시퀀스를 기반으로 **SASRec**을 학습하고, 시점별 **hidden state**를 추출한 뒤 **UMAP**과 **HDBSCAN**을 적용하여 관심사 클러스터를 도출하는 전체 파이프라인의 기본 구조를 구현하였다. 향후에는 현재 파이프라인의 타당성을 검증하고, 모델링 방식과 실험 설정을 확장하는 방향으로 연구를 진행할 예정이다.

임베딩 방식 비교 실험

현재 방식은 사용자의 과거 행동 순서를 반영한 시퀀셜 임베딩을 사용한다. 그러나 이후 단계에서 시점별 **hidden state**를 다시 **clustering**한다면, 반드시 복잡한 **sequence-aware embedding**이 필요한지에 대한 검증이 필요하다. 따라서 향후에는 **SASRec** 기반 시퀀셜 임베딩과 더불어, 단순 아이템 임베딩 기반 표현도 함께 실험하여 비교할 예정이다. 이를 통해 사용자 관심사 클러스터링에서 순서 정보가 실제로 유의미한 성능 향상에 기여하는지 분석한다.

학습 안정성 및 성능 개선

현재 학습된 모델의 **train loss**가 충분히 수렴했는지 추가적인 검토가 필요하다. 향후에는 **train epoch**을 늘리고, **learning rate**, **batch size**, **contrastive loss weight**, **embedding dimension** 등 주요 하이퍼파라미터를 조정하여 모델의 수렴성과 **representation quality**를 개선할 계획이다. 또한 각 실험 설정별 **loss** 변화와 **downstream clustering** 결과를 함께 비교하여, 단순히 **loss**가 낮은 모델이 아니라 관심사 분리에 적합한 표현을 학습하는 모델을 찾고자 한다.

파이프라인 구조 개선

현재는 전체 데이터를 **batch processing** 방식으로 처리하고 있어, 대규모 데이터셋을 다룰 때 메모리 사용량과 처리 시간이 증가하는 한계가 있다. 향후에는 데이터를 한 번에 모두 적재하는 방식이 아니라 **streaming** 방식으로 처리할 수 있는 파이프라인을 구축할 예정이다. 이를 통해 **MovieLens 32M**과 같은 대규모 데이터에서도 안정적으로 전처리, 임베딩 추출, 차원 축소 및 클러스터링을 수행할 수 있도록 개선한다.

모듈별 검증 및 파라미터 튜닝

현재 파이프라인은 데이터 전처리, 임베딩 학습, **hidden state** 추출, **UMAP**, **HDBSCAN**, **scoring**으로 구성된다. 향후에는 각 파트를 독립적으로 실행하고 검증하여, 어느 단계에서 성능 저하나 불안정성이 발생하는지 분석할 예정이다. 특히 **UMAP**의 **n_components**, **n_neighbors**, **min_dist**, **HDBSCAN**의 **min_cluster_size**, **min_samples** 등 클러스터링 결과에 큰 영향을 주는 파라미터를 체계적으로 튜닝할 계획이다.

클러스터 의미 해석 및 메타데이터 결합

HDBSCAN을 통해 도출된 클러스터가 실제로 사용자의 관심사를 의미하는지 확인하기 위해, 각 클러스터에 영화 장르, 태그, 제목 등의 메타데이터를 결합할 예정이다. 이를 통해 특정 클러스터가 **Action**, **Romance**, **Sci-Fi**와 같은 장르 중심으로 형성되는지, 혹은 특정 감독, 분위기, 시대, 태그 기반 취향을 반영하는지 정성적으로 분석한다.

추천 결과 산출 및 검증

현재까지는 파이프라인의 앞단(임베딩, 차원 축소, 클러스터링)을 중심으로 구현을 진행하였다. 향후에는 도출된 관심사 클러스터 중심 벡터와 타겟 아이템 벡터 간의 내적을 통해 최종 추천 스코어를 산출하는 단계를 구현할 예정이다. 이후 **MIND**, **ComiRec**,

SASRec, GRU4Rec 등 비교 모델과의 Recall@K, NDCG@K 기반 정량 평가를 통해 제안 방법의 유효성을 검증한다.

Team member

- 김서정 (팀장) : 스코어링 및 최종 추천 결과 산출
 - 민세희 : 임베딩 모델 설계 및 구현
 - 이재영 : 데이터셋 정제 및 데이터 파이프라인 구축
 - 정지윤 : 클러스터링 기반 모델링 설계 및 구현
-
- 이동하 : 담당 교수
 - 김성환 : 담당 대학원생
 - 박진성 : 산학 멘토

References

[1] MIND

Li, C., Liu, Z., Wu, M., Xu, Y., Zhao, H., Huang, P., Kang, G., Chen, Q., Li, W., & Lee, D. L. (2019).

Multi-Interest Network with Dynamic Routing for Recommendation at Tmall.

In Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19), 2615–2623.

[2] JODIE

Kumar, S., Zhang, X., & Leskovec, J. (2019).

Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks.

In Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '19), 1269–128.

[3] SASRec

Kang, W. C., & McAuley, J. (2018).

Self-Attentive Sequential Recommendation.

In Proceedings of the 2018 IEEE International Conference on Data Mining (ICDM), 197–206.

[4] UMAP

McInnes, L., Healy, J., Saul, N., & Großberger, L. (2018).

UMAP: Uniform manifold approximation and projection.

Journal of Open Source Software, 3(29), 861.

[5] HDBSCAN

Campello, R. J., Moulavi, D., & Sander, J. (2013).

Density-based clustering based on hierarchical density estimates.

In *Advances in Knowledge Discovery and Data Mining: 17th Pacific-Asia Conference, PAKDD 2013, Gold Coast, Australia, April 14-17, 2013, Proceedings, Part II* 17 (pp. 160-172). Springer Berlin Heidelberg.

[6] GRU4rec

Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016).

Session-based Recommendations with Recurrent Neural Networks.

In Proceedings of the International Conference on Learning Representations (ICLR 2016).

[7] ComiRec

Cen, Y., Lin, J., Zhang, J., Zhou, K., Yang, H., & Zhao, W. X. (2020).

Controllable Multi-Interest Framework for Recommendation.

In Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '20).